

基于股票 30 日经验收益率的 Counting Zero 矩阵生成算法

设计目标：让数零任务与股价预测任务的正确答案具有可比较的相对波动，同时保持 15×15 矩阵中 0 和 1 的长期平均比例约为 50:50。

1. 设计问题

现有程序对 225 个格子分别、独立地以 50% 概率生成 0 或 1。因此，0 的数量 X 服从 $\text{Binomial}(225, 0.5)$ ，均值为 112.5，标准差仅为 7.5。正确答案高度集中在 112 和 113 附近，参与者可以通过猜测中心值获得不应有的优势。

$$X \sim \text{Binomial}(225, 0.5), E[X] = 112.5, SD[X] = 7.5$$

简单改为 0 到 225 的离散均匀分布虽然能消除中心集中，但会频繁生成几乎全 0 或几乎全 1 的矩阵，任务难度不稳定，也无法与股价预测任务建立数据基础上的对应关系。

2. 股票任务的经验基准

项目中包含 200 只股票。每只股票向参与者展示 252 个历史交易日，并要求预测随后第 30 个交易日的归一化价格。与预测难度直接相关的收益率，应以最后一个可见历史价格为基准：

$$R_i = P_{i,30} / P_{i,0} - 1$$

统计量	30 日 return	对应含义
最小值	-49.91%	最极端下跌
5% 分位数	-15.12%	中央 90% 下界
中位数	+0.99%	典型观测
均值	+1.36%	样本平均漂移
标准差	12.20%	相对波动尺度
95% 分位数	+19.16%	中央 90% 上界
最大值	+48.65%	最极端上涨

说明：不能使用“正确价格相对于序列第一天 100 的 return”作为映射基准，因为它混合了已展示的 252 日历史变化和真正需要预测的未来 30 日变化。采用最后可见价格到正确答案之间的 30 日 return，才能反映参与者实际面对的不确定性。

3. 推荐的中心化经验映射

每次生成矩阵时，从 200 个真实股票 30 日 return 中等概率抽取一个 R_i 。为了消除股票样本平均上涨造成的 0/1 比例偏移，先减去经验均值 R_{mean} ，再将相对变化映射到以 112.5 为中心的 0 数量：

$$X = \text{round}\{112.5 \times [1 + (R_i - R_{mean})]\}, R_{mean} = 1.3569\%$$

映射完成后，建立 X 个 0 和 $225-X$ 个 1，并使用均匀随机洗牌决定位置。条件于 X ，所有包含 X 个 0 的矩阵具有相同生成概率。

4. 映射后分布的实际性质

统计量	0 的数量 X	解释
最小值	55	对应最极端负 return
5% 分位数	94	中央 90% 下界
25% 分位数	106	下四分位数
中位数	112	分布中心
均值	112.475	约等于 112.5
标准差	13.77	相对标准差约 12.24%
75% 分位数	118	上四分位数
95% 分位数	133	中央 90% 上界
最大值	166	对应最极端正 return

该映射使 $(X-112.5)/112.5$ 与 R_i-R_{mean} 近似相等。因此，两个任务的正确答案具有近似相同的相对离散程度。映射后 $E[X] \approx 112.5$ ，所以任一随机位置长期为 0 的边际概率仍约为 50%。

5. 完整生成步骤

- ① 预先计算所有股票的 30 日 return 列表，并计算其经验均值。
- ② 每道题从 return 列表中等概率、有放回抽取一个 return。
- ③ 使用中心化映射公式计算 0 的数量，并四舍五入为整数。
- ④ 将结果限制在 0 到 225 之间，作为防御性检查。
- ⑤ 建立指定数量的 0 和剩余数量的 1。
- ⑥ 使用 Fisher-Yates 等均匀洗牌方法随机排列全部 225 个格子。
- ⑦ 每 15 个元素切分为一行，形成 15×15 矩阵。

6. Python 参考实现

```
def make_matrix():
    total_cells = C.MATRIX_SIZE ** 2
    sampled_return = random.choice(STOCK_30_DAY_RETURNS)
    centered_return = sampled_return - MEAN_STOCK_RETURN

    zero_count = round(total_cells / 2 * (1 + centered_return))
    zero_count = max(0, min(total_cells, zero_count))

    cells = [0] * zero_count + [1] * (total_cells - zero_count)
    random.shuffle(cells)

    matrix = [cells[i:i + C.MATRIX_SIZE]
              for i in range(0, total_cells, C.MATRIX_SIZE)]
    return matrix, zero_count
```

7. 实施建议

经验抽样方式

建议有放回抽样。每道题都从同一套 200 个 return

中独立抽取，使每道题的边际分布一致，也避免参与者完成较多题目后改变剩余题目的分布。

中心化处理

建议保留中心化。若直接映射原始 return，0 的平均数量约为 114.02，单个格子为 0 的长期概率约为 50.68%。中心化后平均值约为 112.475，更接近严格的 50:50。

可复现性

正式实验应保存每道题抽中的 return、zero_count、矩阵以及随机种子或可追踪的题目标识。这样可以复核正确答案，并验证不同处理组面对的题目分布是否平衡。

极端值

当前经验 return 映射后的范围为 55 到 166，仍远离 0 和 225，不会生成全 0 或全 1 的退化矩阵，因此无需删去极端观测。若未来替换股票库，应重新检查映射范围，并在必要时预先规定截尾规则。

8. 结论

推荐采用“中心化股票 30 日经验 return 重抽样”算法。它比二项伯努利生成方式提供更充分的答案变化，又比人为均匀分布更具实验依据；最重要的是，它使 Counting Zero 与 Stock Forecast 两个任务在正确答案的相对波动上建立了清晰、可复核的对应关系。